

Modul M323 – Funktionales Programmieren

Bank Marketing Data

Kundenanalyse & Abschlussprognose

Projekt-Dokumentation

Autoren: Peter Ngo, Alex Uscata

Klasse: INA 23A

Dozent: Dieter Kopp

Datum: 11. Januar 2026

Inhaltsverzeichnis

1	Einleitung	3
2	Wahl der imperativen Programmiersprache	3
2.1	Begründung der Sprachwahl	3
2.2	Unterstützte funktionale Elemente in Python	3
2.2.1	Kurzbeispiele der funktionalen Elemente	4
3	Datengrundlage	4
3.1	Beschreibung des Datensatzes	4
3.2	Hauptdimensionen	4
3.3	Verwendete Variablen	4
3.4	Herkunft des Datensatzes und Abgrenzung	5
4	Projektantrag	5
4.1	Ausgangslage	5
4.2	Zielsetzung	5
4.3	Projektumfang	6
5	Programmausgabe	6
5.1	Beispielhafter Output	6
5.2	Validierung der Resultate	6
5.3	Interpretation und statistische Einordnung	7
6	Refactoring: Vergleich Version 1.0 vs. Version 2.0	8
6.1	Konkrete Beispiele aus dem Projekt	8
6.1.1	Beispiel A: Filtern von Datensätzen	8
	Imperative Umsetzung (Version 1.0)	8
	Funktionale Umsetzung (Version 2.0)	8
6.1.2	Beispiel B: Gruppierung mit <code>reduce</code> (Group by)	9
	Imperative Umsetzung (Version 1.0)	9
	Funktionale Umsetzung (Version 2.0)	10
6.1.3	Beispiel C: Transformation und Aggregation numerischer Werte (<code>map</code> und <code>sum</code>)	10
	Imperative Umsetzung (Version 1.0)	10
	Funktionale Umsetzung (Version 2.0)	11
6.1.4	Zusammenfassung der Unterschiede	11
7	Fazit	11
7.1	Nutzen funktionaler Elemente	11
7.2	Vereinfachung durch Refactoring	12
7.3	Bewusste Designentscheidungen	12
7.4	Wiederverwendung funktionaler Konzepte	12
7.5	Grenzen funktionaler Elemente in Python	12

7.6 Anwendungsfälle im beruflichen Umfeld	13
8 Ausführung des Programms	13
9 Hinweis zur Entstehung der Arbeit	13
10 Quellen	13
11 Appendix	14
11.1 Projekt-Repository	14
11.2 Weitere Beispielausgaben	14
11.2.1 Menüoption 7: Vergleich zweier Gruppen	14
11.2.2 Menüoption 8: ANOVA-Auswertung	14
11.2.3 Menüoption 1: Erfolgsquote gesamt	14
11.3 Interaktive Konsolen-Ausführung (CLI)	15

1 Einleitung

Im Rahmen des Moduls M323 – Funktionales Programmieren wird in diesem Projekt eine Datenanalyse einer Bank-Marketingkampagne umgesetzt. Ziel ist es, eine imperativ geschriebene Lösung mit einer funktional refaktorierten Version zu vergleichen und die Vor- sowie Nachteile funktionaler Sprachelemente praxisnah zu evaluieren.

Als Datengrundlage dient ein realitätsnaher Datensatz einer portugiesischen Bank, welcher Kundendaten sowie den Erfolg einer Marketingkampagne enthält. Beide Programmversionen erzeugen denselben Output, unterscheiden sich jedoch grundlegend in der Programmierweise.

Die verwendeten Daten werden in Abschnitt 3 beschrieben. Der Einfluss funktionaler Sprachelemente wird anschließend im Refactoring-Vergleich in Abschnitt 6 analysiert.

2 Wahl der imperativen Programmiersprache

2.1 Begründung der Sprachwahl

Für dieses Projekt wurde die Programmiersprache **Python** gewählt. Python eignet sich besonders gut für Datenanalysen, da die Sprache:

- leicht lesbar und verständlich ist
- imperative Programmierung vollständig unterstützt
- funktionale Sprachelemente integriert anbietet
- häufig im beruflichen Umfeld eingesetzt wird

Da Python sowohl imperative als auch funktionale Konzepte vereint, ist die Sprache ideal geeignet, um beide Programmierparadigmen direkt miteinander zu vergleichen.

2.2 Unterstützte funktionale Elemente in Python

Python ist keine rein funktionale Sprache, bietet jedoch zahlreiche funktionale Sprachelemente aus der Standardbibliothek:

- `map()` – Transformation von Daten
- `filter()` – Selektion von Elementen
- `reduce()` (aus `functools`) – Aggregation
- Lambda-Funktionen
- List Comprehensions
- Unveränderliche Datentypen (z. B. Tupel)

Diese Elemente ermöglichen eine deklarative und kompakte Beschreibung von Datenverarbeitungslogik.

2.2.1 Kurzbeispiele der funktionalen Elemente

```
1 # map: Transformation
2 list(map(lambda x: x*x, [1,2,3]))      # -> [1,4,9]
3
4 # filter: Selektion
5 list(filter(lambda x: x > 2, [1,2,3])) # -> [3]
6
7 # reduce: Aggregation
8 from functools import reduce
9 reduce(lambda acc, x: acc + x, [1,2,3], 0) # -> 6
```

Diese funktionalen Konzepte werden im Projekt konkret eingesetzt für:

- Filterung von Datensätzen über Prädikatfunktionen (`apply_filters`)
- Gruppierung von Daten mittels `reduce` (`group_by_key`)
- Numerische Transformationen und Aggregationen (`mean`, ANOVA)

3 Datengrundlage

3.1 Beschreibung des Datensatzes

Als Datengrundlage dient ein Bank-Marketing-Datensatz einer portugiesischen Bank, der auf einer öffentlich dokumentierten Bank-Marketing-Studie basiert (vgl. [1]). Der Datensatz enthält Kundendaten aus einer Marketingkampagne sowie eine Zielvariable, welche angibt, ob ein Produktabschluss erfolgt ist (`complete = yes/no`).

Die Daten liegen in Form einer CSV-Datei vor und wurden im Projekt ausschließlich lesend verwendet.

3.2 Hauptdimensionen

Der Datensatz lässt sich in folgende Hauptdimensionen einteilen:

- **Demografie:** Alter (`age`), Bildungsstand (`education`), Familienstand (`marital`)
- **Finanzen:** Kontostand (`balance`)
- **Kontaktdaten:** Gesprächsdauer (`duration`)
- **Ergebnisvariable:** Produktabschluss (`complete`)

3.3 Verwendete Variablen

Im Projekt werden unter anderem folgende Variablen verwendet:

- `age` (numerisch)
- `job` (kategorisch)
- `marital` (kategorisch)

- `education` (kategorisch)
- `balance` (numerisch)
- `housing` (binär)
- `loan` (binär)
- `duration` (numerisch)
- `complete` (binär, Zielvariable)

3.4 Herkunft des Datensatzes und Abgrenzung

Der im Projekt verwendete Bank-Marketing-Datensatz stammt ursprünglich aus einer universitären Lehrveranstaltung zur multivariaten Datenanalyse an der Universität Basel (vgl. [2]). Der Datensatz wurde im Rahmen eines Assignments zur statistischen Auswertung von Bank-Marketingkampagnen eingesetzt und basiert auf realitätsnahen, vorverarbeiteten Kundendaten einer portugiesischen Bank.

Die Aufgabenstellung des ursprünglichen Assignments umfasste unter anderem Varianzanalysen, logarithmische Transformationen sowie Klassifikationsverfahren. In diesem Projekt wird der Datensatz jedoch ausschließlich als Datengrundlage verwendet und in einen neuen Kontext übertragen.

Die Zielsetzung dieses Projekts unterscheidet sich bewusst von der ursprünglichen universitären Aufgabenstellung: Der Fokus liegt nicht auf statistischer Modellbildung oder Inferenz, sondern auf dem Vergleich imperativer und funktionaler Programmierparadigmen im Sinne des Moduls M323 – Funktionales Programmieren.

4 Projektantrag

4.1 Ausgangslage

Während einer Marketingkampagne hat eine Bank verschiedene Kundendaten erfasst. Der Datensatz liegt in Form einer CSV-Datei vor und ist nicht direkt für Analysen aufbereitet.

Ziel ist es, relevante Kennzahlen zu berechnen, Kundengruppen zu vergleichen und statistische Zusammenhänge zu untersuchen.

4.2 Zielsetzung

Das Projekt verfolgt folgende Ziele:

- Analyse der Erfolgsquote der Marketingkampagne
- Vergleich verschiedener Kundengruppen
- Umsetzung einer imperativen Version (V1.0)
- Refactoring in eine funktionale Version (V2.0)

- Vergleich beider Ansätze hinsichtlich Lesbarkeit und Wartbarkeit

4.3 Projektumfang

Das Projekt umfasst:

- Einlesen und Verarbeiten eines CSV-Datensatzes
- Textbasierte Konsolenausgabe
- Keine externen Bibliotheken
- Umsetzung in Python; Ausführung und Dokumentation der Experimente in einem Jupyter Notebook (Tooling).

5 Programmausgabe

Beide Versionen des Programms erzeugen denselben Output. Die Ausgabe erfolgt textbasiert in der Konsole.

5.1 Beispielhafter Output

Das folgende Beispiel zeigt die Konsolenausgabe der Auswertungsfunktion *Group by Education* (Menüoption 5). Dabei werden alle Datensätze nach Bildungsniveau gruppiert und aggregierte Kennzahlen berechnet, darunter die Anzahl der Kunden, das durchschnittliche Alter, der durchschnittliche Kontostand sowie die Erfolgsquote der Marketingkampagne.

Die dargestellte Ausgabe wird sowohl von Version 1.0 (imperative Umsetzung) als auch von Version 2.0 (funktionale Umsetzung) identisch erzeugt.

```

                                GROUP BY EDUCATION
=====
education | count | avg(age) | avg(balance) | success
-----+-----+-----+-----+-----
primary   | 1002 | 49.0 | 1970.88 | 48.3%
secondary | 3815 | 40.7 | 1709.54 | 52.2%
tertiary  | 2657 | 39.7 | 2404.61 | 62.5%

```

ANOVA F-Wert: 41.93 (df=2,7471)

Hinweis: Version 1.0 (imperativ) und Version 2.0 (funktional) liefern identische Resultate. Weitere exemplarische Konsolenausgaben zu anderen Menüoptionen befinden sich im Appendix (vgl. Abschnitt [11.2](#)).

5.2 Validierung der Resultate

Die automatisierten Tests befinden sich im Verzeichnis `tests/` und können direkt über die Kommandozeile ausgeführt werden:

`python test_outputs.py`

Zur Validierung wurden mehrere automatisierte Tests implementiert, welche die funktionale und die imperative Implementierung systematisch miteinander vergleichen. Ziel dieser Tests ist es, sicherzustellen, dass beide Programmversionen trotz unterschiedlicher Programmierparadigmen identische inhaltliche Resultate liefern.

Konkret wurden folgende Aspekte überprüft:

- Vergleich der Gruppierungsergebnisse (*Group by Education*): Gruppennamen, Gruppengrößen, durchschnittliches Alter, durchschnittlicher Kontostand sowie Erfolgsquoten stimmen in beiden Implementierungen überein.
- Vergleich des berechneten ANOVA-F-Werts inklusive der Freiheitsgrade ($df_{between}$ und df_{within}).
- Invarianzprüfung: Die Summe der Gruppengrößen entspricht stets der Gesamtanzahl der Datensätze, und alle Erfolgsquoten liegen im gültigen Wertebereich $[0, 1]$.
- Determinismus: Mehrfache Ausführungen mit identischen Eingabedaten liefern in beiden Implementierungen stets exakt dieselben Resultate.
- Behandlung von Randfällen: Für unzureichende Datengrundlagen (z. B. leere Datensätze oder nur eine vorhandene Gruppe) liefert die ANOVA-Funktion korrekt den Wert `None`.

Alle Tests wurden erfolgreich ausgeführt und bestätigen die inhaltliche Äquivalenz der funktionalen und imperativen Version. Damit ist sichergestellt, dass die Unterschiede zwischen beiden Programmen ausschließlich in der Programmstruktur und im verwendeten Paradigma liegen, nicht jedoch in den berechneten Ergebnissen.

5.3 Interpretation und statistische Einordnung

Die Ergebnisse zeigen, dass der durchschnittliche Kontostand sowie die Erfolgsquote mit steigendem Bildungsniveau zunehmen. Kunden mit tertiärer Ausbildung weisen sowohl den höchsten durchschnittlichen Kontostand als auch die höchste Erfolgsquote auf.

Zur Bewertung der Unterschiede zwischen den Bildungsgruppen wird eine einfaktorielle Varianzanalyse (ANOVA) verwendet. Der ANOVA-F-Wert beschreibt das Verhältnis der Varianz zwischen den Gruppen zur Varianz innerhalb der Gruppen. Ein hoher F-Wert deutet darauf hin, dass sich die Mittelwerte der Gruppen deutlich voneinander unterscheiden und die Varianz zwischen den Bildungsgruppen größer ist als die Varianz innerhalb der Gruppen.

Die angegebenen Freiheitsgrade (df) geben an, wie viele unabhängige Informationen in die Berechnung eingeflossen sind. Dabei beschreibt $df_{between}$ die Anzahl der verglichenen Gruppen minus eins, während df_{within} die Streuung der Werte innerhalb der Gruppen widerspiegelt [3].

Die Varianzanalyse wird in diesem Projekt ausschließlich deskriptiv verwendet. Der F-Wert dient hier als Maßzahl zur Beschreibung der Stärke von Unterschieden zwischen den Gruppen und nicht als formale Entscheidungsregel im Sinne eines statistischen Signifikanztests. Auf die Berechnung von p-Werten und eine formale Hypothesenprüfung wird daher bewusst verzichtet.

6 Refactoring: Vergleich Version 1.0 vs. Version 2.0

Beide Programmversionen implementieren dieselben Produktfunktionen und erzeugen identische Resultate, unterscheiden sich jedoch in der Umsetzung: Version 1.0 verwendet primär imperative Sprachmittel (Schleifen, Hilfsvariablen, schrittweiser Aufbau von Resultaten), während Version 2.0 die gleiche Logik mit funktionalen Sprachmitteln (z.B. `map`, `filter`, `reduce`, Lambdas) ausdrückt.

6.1 Konkrete Beispiele aus dem Projekt

6.1.1 Beispiel A: Filtern von Datensätzen

In Version 1.0 wird die Filterlogik mit einer Schleife und `continue` umgesetzt. In Version 2.0 wird dieselbe Logik deklarativ als Prädikatfunktion formuliert und per `filter` angewendet.

Imperative Umsetzung (Version 1.0)

Listing 1: Imperative Filterung mittels Schleifen und Kontrollfluss aus `imperative_version.py`

```
68
69 def apply_filters(data: List[Dict[str, Any]], housing: Optional[bool],
    loan: Optional[bool], balance_gt: Optional[float]) -> List[Dict[str,
    Any]]:
70
71     out: List[Dict[str, Any]] = []
72     for row in data:
73         if housing is not None and row.get("housing") is not housing:
74             continue
75         if loan is not None and row.get("loan") is not loan:
76             continue
77         bal = row.get("balance")
78         if balance_gt is not None:
79             if bal is None or bal <= balance_gt:
80                 continue
81         out.append(row)
82     return out
```

Funktionale Umsetzung (Version 2.0)

Listing 2: Funktionale Filterung mittels Prädikatfunktion und `filter` aus `functional_version.py`

```
139
140 def apply_filters(data: List[Dict[str, Any]], housing: Optional[bool],
    loan: Optional[bool], balance_gt: Optional[float]) -> List[Dict[str,
    Any]]:
141
142     def pred(row: Dict[str, Any]) -> bool:
143         if housing is not None and row.get("housing") is not housing:
```

```

144         return False
145     if loan is not None and row.get("loan") is not loan:
146         return False
147     if balance_gt is not None:
148         bal = row.get("balance")
149         if bal is None or bal <= balance_gt:
150             return False
151     return True
152
153     return list(filter(pred, data))

```

Die beiden Codeausschnitte zeigen die Umsetzung derselben Filterlogik in imperativer und funktionaler Form. In der imperativen Version (Listing 1) wird der Datensatz explizit mit einer Schleife durchlaufen, und die Filterbedingungen werden über Kontrollflussanweisungen wie `continue` realisiert. Zwischenergebnisse werden dabei in einer veränderlichen Liste gesammelt.

In der funktionalen Version (Listing 2) wird die Filterlogik in einer separaten Prädikatfunktion gekapselt und anschließend deklarativ mit der Higher-Order-Funktion `filter` auf den gesamten Datensatz angewendet. Dadurch entfällt expliziter Kontrollfluss, und die Logik beschreibt direkt, welche Elemente beibehalten werden sollen, anstatt wie iteriert werden muss.

6.1.2 Beispiel B: Gruppierung mit `reduce` (`Group by`)

Für mehrere Auswertungen (z. B. *Group by Education*) müssen Datensätze nach einem Feldwert gruppiert werden. In Version 1.0 wird dafür schrittweise ein Dictionary aufgebaut und jede Zeile wird in eine veränderliche Liste eingefügt. Version 2.0 formuliert dieselbe Operation als funktionale Faltung (`reduce`), wobei der Akkumulator als unveränderliche Struktur behandelt und bei jedem Schritt neu erzeugt wird.

Imperative Umsetzung (Version 1.0)

Listing 3: Imperative Gruppierung mit Schleifen und veränderlichem Zustand aus `imperative_version.py`

```

234
235 def group_by_key(data: List[Dict[str, Any]], key: str) -> Dict[str,
    List[Dict[str, Any]]]:
236
237     groups: Dict[str, List[Dict[str, Any]]] = {}
238     for row in data:
239         k = row.get(key)
240         k_str = "" if k is None else str(k)
241         if k_str not in groups:
242             groups[k_str] = []
243         groups[k_str].append(row)
244     return groups

```

Funktionale Umsetzung (Version 2.0)

Listing 4: Funktionale Gruppierung mit `reduce` aus `functional_version.py`

```
424
425 def group_by_key(data: List[Dict[str, Any]], key: str) -> Dict[str,
426     Tuple[Dict[str, Any], ...]]:
427
428     def add(acc: Dict[str, Tuple[Dict[str, Any], ...]], row: Dict[str,
429         Any]) -> Dict[str, Tuple[Dict[str, Any], ...]]:
430         k = row.get(key)
431         k_str = "" if k is None else str(k)
432         existing_group = acc.get(k_str, ())
433         new_group = existing_group + (row,)
434         return {**acc, k_str: new_group}
435
436     return reduce(add, data, {})
```

Die folgenden Listings zeigen dieselbe Funktionalität zur Gruppierung von Datensätzen, einmal in imperativer (Listing 3) und einmal in funktionaler Umsetzung (Listing 4). Beide Ausschnitte stammen aus den jeweiligen Implementierungsdateien und wurden zur besseren Vergleichbarkeit isoliert dargestellt.

Die imperative Variante arbeitet mit veränderlichen Datenstrukturen (Dictionary und Listen) und verändert diese schrittweise. Die funktionale Variante beschreibt denselben Prozess als Abbildung von *Akkumulator + Element* auf einen neuen Akkumulator und vermeidet dabei mutierende Operationen. Dadurch wird die Gruppierungslogik deklarativer und lässt sich direkt für mehrere Auswertungen wiederverwenden (z. B. Bildung, Beruf oder Familienstand).

6.1.3 Beispiel C: Transformation und Aggregation numerischer Werte (map und sum)

Die Berechnung des arithmetischen Mittels zeigt exemplarisch, wie numerische Transformation und Aggregation in der funktionalen Version ohne explizite Schleifen oder veränderliche Akkumulatoren umgesetzt werden können. Zunächst werden alle Werte mittels `map` in Gleitkommazahlen transformiert, anschließend erfolgt die Aggregation über `sum`.

Imperative Umsetzung (Version 1.0)

Listing 5: Imperative Berechnung des arithmetischen Mittels mit expliziter Schleife aus `imperative_version.py`

```
117
118 def mean(values: List[float]) -> Optional[float]:
119
120     if not values:
121         return None
122     s = 0.0
123     n = 0
```

```

124     for v in values:
125         s += float(v)
126         n += 1
127     if n == 0:
128         return None
129     return s / float(n)

```

Funktionale Umsetzung (Version 2.0)

Listing 6: Funktionale Berechnung des arithmetischen Mittels mit `map` und `sum` aus `functional_version.py`

```

294
295 def mean(values: List[float]) -> Optional[float]:
296
297     return (sum(map(float, values)) / float(len(values))) if values
    else None

```

Die beiden Listings zeigen die Berechnung des arithmetischen Mittels einmal in imperativer und einmal in funktionaler Form. In der imperativen Version (Listing 5) wird ein veränderlicher Akkumulator (`s`) sowie ein expliziter Zähler (`n`) verwendet, die innerhalb einer Schleife schrittweise aktualisiert werden.

In der funktionalen Version (Listing 6) wird dieselbe Berechnung deklarativ formuliert: Die Transformation der Werte erfolgt über `map`, die Aggregation über `sum`. Ein expliziter Schleifenindex oder ein veränderlicher Zwischenzustand ist nicht notwendig. Dadurch entspricht der Code direkt der mathematischen Definition des Mittelwerts und ist kompakter sowie leichter zu lesen.

6.1.4 Zusammenfassung der Unterschiede

- **Lesbarkeit:** Version 2.0 ist kompakter und beschreibt häufig *was* berechnet wird, statt *wie*.
- **Wartbarkeit:** Wiederverwendbare Hilfsfunktionen (Prädikate, Mapping-Funktionen) reduzieren Duplikation.
- **Fehleranfälligkeit:** Weniger mutable Zwischenzustände und weniger Hilfsvariablen verringern typische Fehlerquellen.

7 Fazit

7.1 Nutzen funktionaler Elemente

Der Einsatz funktionaler Sprachelemente hat in diesem Projekt mehrere Vorteile gebracht. Insbesondere Filter- und Transformationsoperationen konnten kompakter und klarer formuliert werden.

7.2 Vereinfachung durch Refactoring

Im Vergleich zur imperativen Version ist die funktionale Umsetzung nicht zwingend kürzer, jedoch stärker strukturiert. Verschachtelte Schleifen und mutable Hilfsvariablen werden häufig durch deklarative Ausdrücke ersetzt, welche Transformation, Selektion und Aggregation klar voneinander trennen. Der Fokus liegt somit weniger auf der reinen Code-Länge, sondern auf Lesbarkeit, Wartbarkeit und einer geringeren Fehleranfälligkeit.

7.3 Bewusste Designentscheidungen

Im Rahmen der Transformation numerischer Variablen wurden bewusst unterschiedliche mathematische Abbildungen eingesetzt. Neben einer fachlich realistischen Transformation mittels Logarithmus $\log(\text{balance})$ wurde zusätzlich eine einfache quadratische Transformation $\text{balance}^2 + 1$ verwendet.

Der Logarithmus ist insbesondere im wirtschaftlichen Kontext sinnvoll, da er rechtsschiefe Verteilungen reduziert und Ausreißer abschwächt. Allerdings ist diese Transformation nur für positive Werte definiert und erfordert zusätzliche Prüfungen des Wertebereichs.

Die quadratische Transformation hingegen ist für alle numerischen Werte definiert und eignet sich besonders gut, um funktionale Abbildungen unabhängig von Sonderfällen zu demonstrieren. Dadurch konnte der Fokus im Projekt gezielt auf den Vergleich funktionaler Programmierkonzepte gelegt werden, ohne die Darstellung durch zusätzliche Randfallbehandlung zu verkomplizieren.

7.4 Wiederverwendung funktionaler Konzepte

Die funktionalen Konzepte würden in zukünftigen Projekten erneut eingesetzt werden, insbesondere bei:

- Datenfiltern
- Aggregationen
- Transformationen von Listen und Datensätzen

7.5 Grenzen funktionaler Elemente in Python

Obwohl Python zahlreiche funktionale Sprachelemente bereitstellt, handelt es sich nicht um eine rein funktionale Programmiersprache. Im Vergleich zu funktionalen Sprachen wie Haskell werden zentrale Konzepte wie Immutabilität oder Nebenwirkungsfreiheit nicht erzwungen, sondern lediglich konventionell eingehalten.

Variablen können weiterhin verändert werden, und Funktionen können unbeabsichtigt Seiteneffekte erzeugen. Die korrekte Anwendung funktionaler Konzepte hängt somit stark von der Disziplin der Entwickelnden ab und wird nicht durch den Sprachkern abgesichert.

Diese Einschränkungen wurden im Projekt bewusst in Kauf genommen, da der Fokus auf dem Vergleich imperativer und funktionaler Denkweisen innerhalb einer praxisnahen Sprache lag.

In einer rein funktionalen Sprache könnten diese Konzepte konsistenter und durch den Compiler abgesichert umgesetzt werden. Python eignet sich jedoch besonders gut, um funktionale Programmierkonzepte schrittweise in bestehende imperative Arbeitsweisen zu integrieren.

7.6 Anwendungsfälle im beruflichen Umfeld

Im betrieblichen Kontext eignen sich funktionale Sprachelemente besonders für:

- Datenanalyse
- Reporting
- Verarbeitung von Log- oder Kundendaten
- Automatisierte Auswertungen

Zusammenfassend lässt sich sagen, dass funktionale Programmieransätze eine sinnvolle Ergänzung zur imperativen Programmierung darstellen und in vielen Anwendungsfällen zu einer klareren und effizienteren Lösung führen.

8 Ausführung des Programms

Der vollständige Quellcode befindet sich im Projekt-Repository (vgl. [4]). Die Analysen wurden im Rahmen dieses Projekts primär in Jupyter Notebooks durchgeführt, um Auswertungen und Ergebnisse nachvollziehbar zu dokumentieren.

Alternativ kann das Programm auch als Python-Skript ausgeführt werden. Die notwendigen Schritte zur Ausführung sind im Repository dokumentiert.

9 Hinweis zur Entstehung der Arbeit

Zur Unterstützung bei der Dokumentation und beim Refactoring wurden KI-basierte Werkzeuge konsultiert. Die Projektarbeit wurde eigenständig umgesetzt; sämtliche Ergebnisse, Implementierungen und Auswertungen wurden von den Autoren geprüft, verstanden und verantwortet.

10 Quellen

Literatur

- [1] S. Moro, R. Laureano, P. Cortez. *Using Data Mining for Bank Direct Marketing: An Application of the CRISP-DM Methodology*. Proceedings of the European Simulation and Modelling Conference (ESM 2011).
- [2] Maringer, Dietmar und Kitzing, Emil. *Multivariate Datenanalyse – Assignment 1*. WWZ, Universität Basel, Herbstsemester 2024.
- [3] Montgomery, Douglas C. *Design and Analysis of Experiments*. 9th Edition, Wiley, 2022.
- [4] Projekt-Repository: <https://github.com/stoicfist/Modul-323-Projektarbeit>

Hinweis: Der vollständige Quellcode wurde in dieser Dokumentation bewusst nicht vollständig abgedruckt, um den Fokus auf Konzept und Vergleich zu legen (vgl. [4]).

11 Appendix

11.1 Projekt-Repository

Der vollständige Quellcode des Projekts ist im öffentlichen GitHub-Repository verfügbar (vgl. [4]).

11.2 Weitere Beispielausgaben

11.2.1 Menüoption 7: Vergleich zweier Gruppen

Verfügbare Gruppen in 'education': primary, secondary, tertiary

```
=====
                        VERGLEICH ZWEIER GRUPPEN
=====
education | count | avg(age) | avg(balance) | avg(duration) | success
-----+-----+-----+-----+-----+-----
tertiary   | 2657 |    39.7 |    2404.61 |        382.4 |    62.5%
secondary  | 3815 |    40.7 |    1709.54 |        387.2 |    52.2%
```

Erfolgsquote (A-B): +10.3%

11.2.2 Menüoption 8: ANOVA-Auswertung

```
=====
                        ANOVA-ÄHNLICHER F-WERT (BALANCE)
=====
F(2, 7471) = 41.928
```

Interpretation: Deutliche Unterschiede der Mittelwerte zwischen Gruppen möglich (hoher F-Wert).

11.2.3 Menüoption 1: Erfolgsquote gesamt

```
=====
                        ERFOLGSQUOTE
=====
Metric | Value
-----+-----
Total  | 7474
Yes     | 4137
Quote  | 55.4%
```

11.3 Interaktive Konsolen-Ausführung (CLI)

Neben der Ausführung im Jupyter Notebook kann das Programm auch direkt als Python-Skript gestartet werden. Dabei wird eine textbasierte Benutzeroberfläche angezeigt, welche die Bedienung über ein Menü ermöglicht:

```
=====
                        BANK MARKETING - CLI
=====

                        Datensätze geladen: 7474
=====

                        MENU
=====

1) Erfolgsquote gesamt
2) Filter setzen (housing/loan/balance>X)
3) Transformationen (log(balance), balance^2+1)
4) duration Analyse + optional Buckets
5) Group by education
6) Group by marital
7) Vergleich zweier Gruppen
8) ANOVA-ähnlicher F-Wert (balance)
q) Quit
Auswahl: 7
=====

                        VERGLEICH ZWEIER GRUPPEN
=====

Gruppierungsfeld (education/marital/job) [Default: education]:
Verfügbare Gruppen:
primary, secondary, tertiary
Gruppe A: secondary
Gruppe B: tertiary
education | count | avg(age) | avg(balance) | avg(duration) | success
-----+-----+-----+-----+-----+-----
secondary | 3815 | 40.7 | 1709.54 | 387.2 | 52.2%
tertiary | 2657 | 39.7 | 2404.61 | 382.4 | 62.5%
Erfolgsquote (A-B): -10.3%
```